



UNIVERSIDAD SERGIO ARBOLEDA

**BÚSQUEDA LOCAL EN EL 8-PUZZLE:
ASCENSO DE COLINAS Y TEMPLE SIMULADO**

Introducción a la Inteligencia Artificial

Mario Jiménez

Juan David Andrade

Camilo Andrés Díaz García

*Universidad Sergio Arboleda
Facultad de Sistemas e Ingeniería
Bogotá D.C., 2026*

Índice

1. Introducción	2
2. Metodología	2
2.1. Enfoque: búsqueda local	2
2.2. Formulación del 8-puzzle	3
2.3. Conjunto de pruebas	4
2.4. Algoritmos	5
2.4.1. Ascenso de colinas: más pronunciado y estocástico	5
2.4.2. Reinicios por perturbación y elección de K	5
2.4.3. Temple simulado	7
2.5. Métricas	9
2.6. Diseño experimental	9
2.6.1. Varias semillas por tablero	9
2.6.2. Presupuesto compartido de evaluaciones	10
2.6.3. Barrido de T_0 y α	10
2.7. Configuraciones comparadas	11
3. Resultados	11
3.1. Tabla principal	11
3.2. Longitud de la solución	12
3.3. Ascenso puro y degradación del temple	13
3.4. Trazas de temple	14
3.5. Barrido de T_0 y α	15
3.6. Barrido de K (análisis aparte)	16
3.7. Temple sin tope de evaluaciones	17
4. Análisis	17
4.1. El 8-puzzle exige tolerar empeoramientos	17
4.2. Los dos mecanismos para aceptar empeoramientos	18
4.3. La calibración decide el resultado	18
4.4. Por qué K grande no es una perturbación local	18
4.5. Tasa de éxito frente a calidad de la solución	19
5. Conclusiones	20
Referencias	21

1 Introducción

Este taller aplica búsqueda local al 8-puzzle y compara dos familias de algoritmos: el ascenso de colinas, en tres variantes (más pronunciado, estocástico y con reinicios), y el temple simulado. El objetivo no es solo reportar cuál resuelve más tableros, sino mostrar con evidencia cómo se adapta cada algoritmo a la estructura del problema y qué decisiones de diseño hicieron falta para que la comparación fuera justa.

Todos los algoritmos se evaluaron sobre el mismo conjunto de 30 tableros resolubles, con el mismo presupuesto de evaluaciones de la función objetivo y con 10 semillas aleatorias por tablero. Los parámetros de temple simulado se eligieron con un barrido sistemático, y el largo de la perturbación de los reinicios se fijó con un criterio derivado del diámetro del espacio de estados. Además de la tasa de éxito se midió el costo (evaluaciones de h) y la calidad de la solución encontrada (número de movimientos frente a la solución óptima de cada tablero).

Este documento presenta la metodología, con la teoría necesaria en cada paso, y el análisis de los resultados. La implementación completa, los experimentos reproducibles y las tablas y figuras junto al código que las genera están en el cuaderno adjunto (`taller_8puzzle.ipynb`) y en el repositorio del equipo (https://github.com/CamiloDGO7/Taller_Colina-Temple). Los fragmentos de código que aparecen aquí son capturas generadas directamente desde ese código fuente, así que sus números de línea coinciden con los de los archivos.

2 Metodología

Esta sección describe el problema, los algoritmos y el diseño de los experimentos. Los conceptos teóricos y las fórmulas se presentan en el punto donde se usan, junto a la decisión de diseño que sostienen.

2.1 Enfoque: búsqueda local

Los algoritmos de búsqueda clásicos (anchura, profundidad, A*) exploran el espacio de estados de forma sistemática y guardan en memoria los caminos desde el estado inicial. La búsqueda local sigue otra idea: mantiene uno o pocos estados actuales y se mueve solo a estados vecinos, sin recordar los caminos recorridos [5]. Tiene dos ventajas: usa muy poca memoria (constante, en la práctica) y puede encontrar soluciones razonables en espacios enormes o continuos donde una búsqueda sistemática no es viable.

La búsqueda local trabaja con una *formulación de estado completo*: cada estado es una configuración completa del problema y el algoritmo la va modificando. La calidad de un estado se mide con una función objetivo; en este taller se minimiza una función de

costo $h(s)$, cuyo mínimo global ($h = 0$) corresponde a la meta.

Es útil imaginar el espacio de estados como un paisaje, donde la posición es el estado y la altura es el valor de h . Un algoritmo de minimización busca el valle más profundo. Las dificultades clásicas son [5]:

- **Mínimos locales:** estados en los que todos los vecinos tienen h mayor o igual, pero que no son el mínimo global. Un algoritmo que solo acepta mejoras queda atrapado en ellos.
- **Mesetas:** regiones donde los vecinos tienen el mismo valor de h , sin gradiente que indique hacia dónde avanzar.
- **Crestas:** secuencias de mínimos locales que exigen una combinación de movimientos, y no uno solo, para mejorar.

Un algoritmo de búsqueda local es *completo* si siempre encuentra una meta cuando existe, y *óptimo* si encuentra el mínimo global. Un algoritmo que nunca acepta empeorar es incompleto: puede quedar atrapado en un mínimo local. Un paseo puramente aleatorio es completo en un espacio finito, pero extremadamente ineficiente. Los algoritmos de este taller combinan de distintas formas la explotación (moverse hacia menor h) y la exploración (aceptar movimientos que no mejoran).

2.2 Formulación del 8-puzzle

El 8-puzzle es un tablero de 3×3 con ocho fichas numeradas y una casilla vacía. Un movimiento desliza una ficha adyacente a la casilla vacía hacia ella. La meta es el tablero ordenado (1, 2, 3, 4, 5, 6, 7, 8, vacía).

- **Estado:** una tupla de 9 valores con la posición de cada ficha (0 representa la casilla vacía).
- **Vecindad:** los estados que se obtienen con un movimiento legal de la casilla vacía (arriba, abajo, izquierda o derecha). Cada estado tiene entre 2 y 4 vecinos según la posición de la casilla vacía (esquina, borde o centro).
- **Función objetivo:** la distancia Manhattan,

$$h(s) = \sum_{i=1}^8 (|f_i(s) - f_i^*| + |c_i(s) - c_i^*|), \quad (1)$$

donde $(f_i(s), c_i(s))$ es la posición de la ficha i en el estado s y (f_i^*, c_i^*) su posición en la meta. Se cumple $h(s) = 0$ si y solo si s es la meta.

La Figura 1 muestra la implementación de la función objetivo. Recorre las nueve casillas, salta la vacía (líneas 38 y 39) y suma la distancia horizontal y vertical de cada ficha a su posición en la meta (líneas 40 a 43). Como cada término es no negativo y solo vale 0 cuando la ficha ya está en su lugar, $h(s) = 0$ únicamente en la meta. Eso permite usar la misma condición, $h = 0$, como criterio de éxito en todos los algoritmos.

```
src/formulacion.py  líneas 25-44
25 def distancia_manhattan(estado, meta=META):
26     """Suma de distancias Manhattan de cada ficha a su lugar meta.
27
28     El 0 (casilla vacia) no se cuenta: no es una ficha que deba
29     moverse a un lugar especifico. h(s) = 0 unicamente en la meta,
30     ya que la distancia Manhattan de una ficha es 0 solo si ya esta
31     en su posicion objetivo, y la suma de terminos no negativos es
32     0 solo si todos lo son.
33     """
34     posiciones_meta = (
35         POSICIONES_META if meta is META else _posiciones_meta(meta))
36     total = 0
37     for indice, ficha in enumerate(estado):
38         if ficha == 0:
39             continue
40         fila_actual, columna_actual = fila_columna(indice)
41         fila_meta, columna_meta = fila_columna(posiciones_meta[ficha])
42         total += (abs(fila_actual - fila_meta)
43                 + abs(columna_actual - columna_meta))
44     return total
```

Figura 1: Función objetivo $h(s)$: distancia Manhattan. Fuente: elaboración propia (src/formulacion.py).

Dos propiedades de esta formulación son importantes para el análisis:

1. **Cada movimiento cambia h exactamente en ± 1 :** un movimiento desplaza una sola ficha una casilla, y esa ficha se acerca o se aleja de su destino en una unidad. Por eso no hay movimientos laterales ($\Delta h = 0$) ni mesetas en sentido estricto. Esta propiedad se verificó en el código (verificar_delta_h).
2. **Solo la mitad de los tableros es resoluble:** de los $9! = 362\,880$ tableros posibles, solo $9!/2 = 181\,440$ pueden llegar a la meta. Un tablero es resoluble si su número de inversiones (pares de fichas en orden inverso, sin contar la casilla vacía) es par [1]. El generador de tableros de prueba solo produce tableros resolubles.

Además, la solución óptima de cualquier tablero resoluble tiene como máximo 31 movimientos: ese es el *diámetro* del espacio de estados [4]. Este dato se verificó en este trabajo con una búsqueda en anchura desde la meta sobre los 181 440 estados resolubles: la distancia máxima encontrada fue exactamente 31. La misma búsqueda da la longitud óptima de cada tablero de prueba, que se usa para medir la calidad de las soluciones.

2.3 Conjunto de pruebas

Se generaron 30 tableros resolubles con semilla fija (42), aplicando el criterio de paridad de inversiones. Su h inicial promedio es 13.97 (entre 6 y 20), y su solución óptima

promedio es de 22.5 movimientos (entre 16 y 28), calculada con la búsqueda en anchura descrita en la formulación.

2.4 Algoritmos

2.4.1 Ascenso de colinas: más pronunciado y estocástico

El ascenso de colinas (*hill climbing*) es la búsqueda local más simple: en cada paso se mueve a un vecino que mejora la función objetivo y se detiene cuando ninguno la mejora [5]. Es un algoritmo voraz: toma la mejor decisión local sin considerar consecuencias futuras. Se implementaron dos variantes:

- **Más pronunciado** (*steepest ascent*): evalúa todos los vecinos y se mueve al de menor h . Es determinista.
- **Estocástico**: evalúa todos los vecinos y elige al azar entre los que mejoran h . Suele avanzar más despacio, pero a veces encuentra mejores soluciones en paisajes con muchas direcciones de mejora.

Las dos se detienen en el primer mínimo local. En el 8-puzzle, como $\Delta h = \pm 1$, un paso de ascenso siempre baja h en exactamente 1, así que el camino de un ascenso tiene como máximo $h(s_0)$ movimientos y nunca retrocede.

2.4.2 Reinicios por perturbación y elección de K

El ascenso con reinicios aleatorios (*random restart*) repite el ascenso desde distintos puntos de partida hasta encontrar la meta o agotar un presupuesto. Si cada intento tiene probabilidad p de éxito, el número esperado de intentos es $1/p$, y el algoritmo es completo con probabilidad que tiende a 1 [5]. Como no tiene un criterio de parada propio, necesita un presupuesto de evaluaciones.

La primera implementación de reinicios partía de tableros resolubles generados al azar, sin relación con el tablero asignado. Llegó a 99.0% de éxito, pero ninguno de los 300 intentos exitosos partía del tablero asignado: resolvía otros tableros, no el que se le pedía, y no producía una secuencia de movimientos que resolviera el tablero dado. Por eso se reemplazó por **reinicios por perturbación**: el primer intento es un ascenso más pronunciado desde el tablero asignado; si queda en un mínimo local, cada reinicio hace una caminata aleatoria de K movimientos legales partiendo siempre del tablero asignado y vuelve a aplicar el ascenso. Así, todo intento exitoso (caminata más ascenso) es una solución real del tablero asignado.

La caminata (Figura 2) aplica K movimientos legales, cada uno elegido al azar entre los vecinos del estado actual (líneas 79 a 81). Como usa la misma función vecinos que el

resto de los algoritmos, el tablero que produce siempre es alcanzable desde el de partida. La caminata no calcula h , así que sus movimientos no cuentan como evaluaciones.

```
src/ascenso.py   líneas 75-82
75 def caminata_aleatoria(tablero, cantidad_movimientos, generador):
76     """Aplica `cantidad_movimientos` movimientos legales elegidos al
77     azar (uniforme entre los vecinos) a partir de `tablero`."""
78     estado = tablero
79     for _ in range(cantidad_movimientos):
80         candidatos = vecinos(estado)
81         estado = candidatos[generador.integers(0, len(candidatos))]
82     return estado
```

Figura 2: Caminata aleatoria de K movimientos legales usada para perturbar el tablero. Fuente: elaboración propia (src/ascenso.py).

El bucle principal de reinicios (Figura 3) muestra por qué la solución sigue siendo real. En la primera vuelta, tablero es el tablero asignado, así que el primer intento es un ascenso directo. Cada reinicio siguiente parte de una caminata que empieza *siempre* en tablero_inicial (líneas 135 y 136), no en el punto de partida del reinicio anterior; si las caminatas se encadenaran, el algoritmo se alejaría cada vez más del tablero asignado. Cuando un intento llega a $h = 0$, la solución es la caminata de ese intento seguida de los pasos del ascenso, y su longitud se registra como la suma de ambos (línea 132). El costo del punto de partida y del ascenso se descuenta del presupuesto (líneas 123 y 127).

```
src/ascenso.py   líneas 121-140
121 while evaluaciones_totales < presupuesto_evaluaciones:
122     h_inicial = distancia_manhattan(tablero)
123     evaluaciones_totales += 1
124     h_iniciales.append(h_inicial)
125
126     resultado = steepest(tablero)
127     evaluaciones_totales += resultado.evaluaciones
128
129     if mejor_h is None or resultado.h_final < mejor_h:
130         mejor_estado, mejor_h = resultado.estado_final, resultado.h_final
131         estado_partida = tablero
132         longitud_solucion = movimientos_caminata + resultado.movimientos
133     if mejor_h == 0:
134         break
135     tablero = caminata_aleatoria(
136         tablero_inicial, movimientos_perturbacion, generador)
137     movimientos_caminata = movimientos_perturbacion
138 return ResultadoReinicios(
139     mejor_estado, mejor_h, evaluaciones_totales, h_iniciales,
140     estado_partida, len(h_iniciales), longitud_solucion)
```

Figura 3: Bucle de reinicios por perturbación: cada reinicio parte del tablero asignado. Fuente: elaboración propia (src/ascenso.py).

El largo K de la caminata se fijó en $K = 20$ usando el diámetro del espacio de estados (31, ver la formulación). Con $K < 31$ la caminata sigue siendo una modificación local del tablero asignado. Con $K \geq 31$ ya tiene alcance para llegar a cualquier tablero resoluble, y el reinicio se parece cada vez más a generar un tablero al azar. $K = 20$ es el mayor valor

redondo por debajo de ese umbral. El barrido $K \in \{10, 20, 50, 100, 200\}$ se reporta aparte como análisis del efecto de K , no como criterio de selección.

En el código, la decisión queda fijada como una constante documentada y no como un número suelto (Figura 4): el comentario registra el umbral del diámetro y aclara que el barrido de K no elige el valor principal (líneas 70 a 72). Así, quien lea el código encuentra la misma justificación que este informe.

```
src/experimentos.py  líneas 62-74
62 # K_PRINCIPAL es el que va en la tabla comparativa. Se fija por el
63 # diámetro del espacio de estados del 8-puzzle: ningún tablero
64 # resoluble necesita más de 31 movimientos para llegar a la meta. Con
65 #  $K < 31$  la caminata sigue siendo una modificación local del tablero
66 # asignado; con  $K \geq 31$  ya tiene alcance para llegar a cualquier
67 # tablero resoluble y el reinicio se parece a generar un tablero al
68 # azar.  $K = 20$  es el mayor  $K$  redondo por debajo de ese umbral.
69 #
70 # El barrido de  $K$  (VALORES_K_BARRIDO) NO elige la  $K$  principal: se
71 # reporta aparte como análisis del efecto de  $K$  sobre la tasa de éxito
72 # y la longitud de la solución.
73 DIAMETRO_8PUZZLE = 31
74 K_PRINCIPAL = 20
```

Figura 4: Elección de K por el diámetro del espacio de estados. Fuente: elaboración propia (src/experimentos.py).

2.4.3 Temple simulado

El temple simulado (*simulated annealing*) se inspira en el recocido de metales: un material calentado y enfriado lentamente alcanza una estructura cristalina de baja energía [2]. El algoritmo trata $h(s)$ como la energía del estado. En cada iteración elige un vecino al azar y calcula $\Delta E = h(s') - h(s)$:

- si $\Delta E \leq 0$ (el vecino no empeora), lo acepta siempre;
- si $\Delta E > 0$ (el vecino empeora), lo acepta con probabilidad

$$P(\text{aceptar}) = e^{-\Delta E/T}, \quad (2)$$

que es el criterio de Metropolis [3].

La temperatura T controla el equilibrio entre exploración y explotación. Con T alta casi todo empeoramiento se acepta y el algoritmo se comporta como un paseo aleatorio. Con T cercana a 0 casi ningún empeoramiento se acepta y el algoritmo se vuelve un ascenso de colinas. En el 8-puzzle, como $\Delta E = +1$ en todo empeoramiento, la probabilidad de aceptarlo depende solo de T : vale $e^{-1} \approx 0.37$ con $T = 1$, $e^{-2} \approx 0.14$ con $T = 0.5$ y e^{-20} (prácticamente cero) con $T = 0.05$.

A diferencia del ascenso de colinas, el estado actual del temple puede empeorar; por eso la implementación guarda aparte el mejor estado visto, que nunca empeora. El temple

no tiene memoria de los estados visitados: puede aceptar un movimiento que deshace el anterior y volver a zonas ya exploradas.

La Figura 5 muestra el núcleo de la implementación: una iteración de temple con la temperatura actual. Las líneas 72 a 77 son el criterio de Metropolis. Si el vecino no empeora ($\Delta E \leq 0$) se acepta siempre (líneas 73 y 74); si empeora, se acepta solo cuando un número aleatorio uniforme cae por debajo de $e^{-\Delta E/T}$ (líneas 76 y 77). Esa rama es la que permite al temple salir de un mínimo local, y es exactamente lo que le falta al ascenso de colinas. Otros tres detalles del fragmento sostienen decisiones posteriores:

- cada vecino evaluado suma una evaluación (líneas 69 y 70), el mismo criterio de costo que en el ascenso de colinas;
- el mejor estado se guarda aparte y solo cambia cuando mejora (líneas 82 y 83), así que el resultado final nunca empeora aunque el estado actual sí lo haga;
- `movimientos_aceptados` cuenta todos los movimientos aceptados, incluidos los que empeoran h (línea 81); por eso la longitud de la solución del temple incluye su zigzag.

```
src/temple.py  líneas 65-84
65     for _ in range(iteraciones_por_temperatura):
66         candidatos = vecinos(estado_actual)
67         indice = generador.integers(0, len(candidatos))
68         vecino = candidatos[indice]
69         h_vecino = distancia_manhattan(vecino)
70         evaluaciones += 1
71
72         delta_energia = h_vecino - h_actual
73         if delta_energia <= 0:
74             aceptar = True
75         else:
76             probabilidad = math.exp(-delta_energia / temperatura)
77             aceptar = generador.random() < probabilidad
78
79         if aceptar:
80             estado_actual, h_actual = vecino, h_vecino
81             movimientos_aceptados += 1
82             if h_actual < mejor_h:
83                 mejor_estado, mejor_h = estado_actual, h_actual
84                 movimientos_hasta_mejor = movimientos_aceptados
```

Figura 5: Una iteración de temple simulado: criterio de aceptación de Metropolis. Fuente: elaboración propia (`src/temple.py`).

La temperatura baja con enfriamiento geométrico: se hacen L iteraciones con cada temperatura y después se actualiza $T_{k+1} = \alpha T_k$, desde T_0 hasta $T \leq T_{\min}$. La ejecución también se detiene si h llega a 0. Los parámetros son la temperatura inicial T_0 , el factor de enfriamiento $\alpha \in (0, 1)$, las iteraciones por nivel L y la temperatura mínima $T_{\min}$. El número de niveles de temperatura es

$$N = \left\lceil \frac{\ln(T_{\min}/T_0)}{\ln \alpha} \right\rceil, \quad (3)$$

y el costo máximo de una corrida es de unas $N \cdot L$ evaluaciones. Existe un resultado teórico que garantiza la convergencia al óptimo global con un enfriamiento logarítmico suficientemente lento [5], pero ese ritmo es impracticable. En la práctica, elegir T_0 y α es un compromiso entre calidad y costo; por eso se eligieron con un barrido (Sección 2.6.3).

Los otros dos parámetros quedaron fijos en $L = 100$ iteraciones por nivel y $T_{\min} = 0.05$. Con $T = 0.05$, aceptar un empeoramiento tiene probabilidad e^{-20} : el temple ya está congelado. Se probó $T_{\min} = 0.01$ (el valor de un cuaderno exploratorio previo): temple de la actividad sin tope dio exactamente la misma tasa de éxito (70.3%), pero gastó 11 395 evaluaciones en lugar de 9823, porque solo alarga la cola del enfriamiento. Bajarlo habría inflado el presupuesto compartido sin cambiar el resultado.

2.5 Métricas

- **Tasa de éxito:** porcentaje de tableros resueltos ($h = 0$). Se calcula por separado en cada semilla, sobre los 30 tableros, y se reporta el promedio, la desviación estándar, el mínimo y el máximo entre las 10 semillas.
- **h final:** valor de h del mejor estado encontrado.
- **Evaluaciones:** número de llamadas a $h(s)$, con el mismo criterio en todos los algoritmos (una por cada estado evaluado, incluido el inicial). Es la medida de costo computacional.
- **Porcentaje de corridas truncadas:** corridas que agotaron el presupuesto de evaluaciones sin llegar a $h = 0$, con el mismo criterio para temple y para reinicios.
- **Longitud de la solución:** número de movimientos de la secuencia que lleva del tablero asignado a la meta, solo en corridas resueltas. En temple son los movimientos aceptados hasta llegar a $h = 0$; en reinicios, los movimientos de la caminata del intento exitoso más los pasos del ascenso. No se eliminan los ciclos (movimientos que se deshacen).
- **Razón sobre la óptima:** longitud de la solución dividida por la longitud óptima del mismo tablero.

2.6 Diseño experimental

2.6.1 Varias semillas por tablero

Todo lo aleatorio (estocástico, reinicios y temple, incluidos los barridos) se repitió con 10 semillas por tablero, es decir, 300 corridas por configuración. Steepest es determinista y corre una vez por tablero. La decisión surgió de una prueba: la misma configuración de temple ($T_0 = 10$, $\alpha = 0.97$), corrida una sola vez sobre los 30 tableros con 8 semillas

distintas, dio tasas de éxito de 53.3 %, 66.7 %, 66.7 %, 70.0 %, 70.0 %, 73.3 %, 76.7 % y 90.0 %. Un rango de 37 puntos para una misma configuración es mayor que la mayoría de las diferencias entre configuraciones: una sola corrida no alcanza para comparar algoritmos estocásticos.

Cada corrida usa su propio generador de números aleatorios, con una semilla derivada de la configuración, la semilla y el tablero. En temple, la semilla depende de (T_0, α) y no del experimento que la corre, así que una misma configuración da exactamente los mismos números en el barrido y en la tabla principal.

2.6.2 Presupuesto compartido de evaluaciones

Para comparar con el mismo costo computacional, todas las configuraciones aleatorias de la tabla principal (reinicios, temple de la actividad y temple mejor) y todos los barridos usan el mismo tope de evaluaciones: **9823**. Es el promedio de evaluaciones que gasta temple con la configuración de la actividad ($T_0 = 10$, $\alpha = 0.97$) cuando corre hasta su parada natural. Reinicios necesita un tope porque no tiene criterio de parada propio, y el temple lo necesita para que una configuración no gane solo por enfriar más lento y gastar más evaluaciones.

Para que el porcentaje de corridas truncadas sea comparable entre algoritmos, temple y reinicios usan la misma función para decidir si una corrida fue truncada (Figura 6). Una corrida queda truncada solo si tenía presupuesto, no llegó a $h = 0$ y gastó todo el presupuesto (líneas 201 a 203). Una corrida que termina por su parada natural (temple que llega a $T_{\min}$) o que resuelve el tablero justo al agotar el presupuesto no cuenta como truncada.

```
src/experimentos.py  líneas 196-203
196 def _es_truncada(resultado, presupuesto_evaluaciones):
197     """Una corrida queda truncada cuando la corto el presupuesto de
198     evaluaciones sin llegar a h = 0, y no su parada natural. Mismo
199     criterio para temple y para reinicios."""
200     return (
201         presupuesto_evaluaciones is not None
202         and resultado.h_final > 0
203         and resultado.evaluaciones >= presupuesto_evaluaciones)
```

Figura 6: Criterio de truncado compartido por temple y reinicios. Fuente: elaboración propia (src/experimentos.py).

2.6.3 Barrido de T_0 y α

La mejor configuración de temple se eligió con un barrido sobre la grilla

$$T_0 \in \{0.5, 1, 2, 5, 10, 20, 40\}, \quad \alpha \in \{0.90, 0.95, 0.97, 0.99, 0.995, 0.998\}$$

(42 combinaciones), sobre los 30 tableros, con 10 semillas y el presupuesto compartido. Se eligió la de mayor tasa de éxito promedio y, en caso de empate, la de menos evalua-

ciones. Una primera versión del barrido usaba 10 tableros y una grilla sin T_0 bajos ni α altos; se amplió porque la muestra chica elegía configuraciones que después rendían peor en el conjunto completo, y porque la zona de T_0 bajo y α alto era justo donde el cuaderno exploratorio había encontrado buenos resultados.

Las combinaciones que enfrían lento no alcanzan a llegar a $T_{\min}$ dentro del presupuesto y quedan truncadas. Se dejaron competir así a propósito: el barrido responde qué configuración rinde más con el mismo costo, y enfriar lento es justamente gastar más evaluaciones.

2.7 Configuraciones comparadas

Tabla 1: Configuraciones de la tabla principal

Configuración	Descripción
Steepest	Ascenso más pronunciado desde el tablero asignado.
Estocástico	Ascenso estocástico desde el tablero asignado.
Reinicios	Reinicios por perturbación con $K = 20$, presupuesto 9823.
Temple (actividad)	$T_0 = 10$, $\alpha = 0.97$, presupuesto 9823.
Temple (mejor)	$T_0 = 1$, $\alpha = 0.998$ (ganadora del barrido), presupuesto 9823.

En todas las configuraciones de temple, $L = 100$ y $T_{\min} = 0.05$.

3 Resultados

3.1 Tabla principal

Tabla 2: Resultados con el mismo presupuesto (30 tableros, 10 semillas)

Configuración	Éxito (%)	Desv.	Mín-máx	h final	Evaluac.	Trunc. (%)
Steepest	0.0	0.00	0.0–0.0	12.53	7.4	0.0
Estocástico	0.0	0.00	0.0–0.0	12.35	7.9	0.0
Reinicios ($K = 20$)	32.7	5.54	26.7–43.3	2.92	7568.7	67.3
Temple (actividad)	68.0	7.02	56.7–80.0	1.05	7563.6	32.0
Temple (mejor)	96.3	4.07	86.7–100	0.13	3074.5	3.7




Figura 7: Tasa de éxito promedio por configuración; las barras de error son la desviación estándar entre semillas. Fuente: elaboración propia.




Figura 8: Evaluaciones promedio de h por configuración. Fuente: elaboración propia.

3.2 Longitud de la solución

Tabla 3: Longitud de la solución en las corridas resueltas

Configuración	Resueltas	Longitud prom.	Mín-máx	Veces la óptima
Reinicios ($K = 20$)	98/300	31.5	24–40	1.6
Temple (actividad)	204/300	5384.9	860–6984	245.0
Temple (mejor)	289/300	1473.7	51–4756	66.9

Steepest y estocástico no resolvieron ningún tablero. La solución óptima promedio es de 22.5 movimientos en el conjunto completo; en los tableros que resuelve reinicios es de

19.9, y en los que resuelve temple mejor, de 22.5. Ninguna configuración encontró nunca la solución óptima exacta de un tablero.

Reinicios aleatorios: caso resuelto (con perturbación de 20 movimientos, 100 intentos) Solución de 27 movimientos						Temple (mejor): caso resuelto Solución de 1926 movimientos					
Antes ($h = 13$)			Después ($h = 0$)			Antes ($h = 14$)			Después ($h = 0$)		
1	6	8	1	2	3		1	6	1	2	3
3	5		4	5	6	3	4	7	4	5	6
4	7	2	7	8		8	2	5	7	8	

Figura 9: Casos resueltos por reinicios ($K = 20$) y por temple mejor, con la longitud de la solución de cada uno. Fuente: elaboración propia.

3.3 Ascenso puro y degradación del temple




Figura 10: h final por tablero: steepest, temple con $\alpha = 0.01$ (enfriamiento casi inmediato) y temple mejor. Fuente: elaboración propia.

Steepest hace en promedio 1.4 movimientos antes de quedar atrapado: la mayoría de los tableros de prueba ya están en un mínimo local o muy cerca de uno. Temple con $\alpha = 0.01$ tampoco resolvió ninguno de los 30 tableros (h final promedio 9.57): después del primer nivel de temperatura, T ya es tan baja que solo acepta mejoras y se comporta como un ascenso de colinas.

3.4 Trazas de temple




Figura 11: Evolución de h actual y h mejor en una corrida de temple mejor (tablero 1), al final de cada nivel de temperatura. Fuente: elaboración propia.




Figura 12: Evolución de h en una corrida de temple de la actividad (tablero 1). Fuente: elaboración propia.

3.5 Barrido de T_0 y α

Tabla 4: Las seis mejores combinaciones del barrido $T_0 \times \alpha$

T_0	α	Éxito (%)	Desv.	Evaluac.	Trunc. (%)
1	0.998	96.3	4.1	3074.5	3.7
1	0.995	93.7	5.7	3220.1	6.3
2	0.99	90.7	2.5	4363.0	9.3
2	0.995	87.3	5.5	4750.5	12.7
1	0.99	78.3	8.9	3913.2	21.7
2	0.998	77.3	8.0	5665.2	22.7




Figura 13: Tasa de éxito para cada combinación de T_0 y α (una curva por T_0). Fuente: elaboración propia.




Figura 14: Efecto de T_0 con $\alpha = 0.97$ (izquierda) y de α con $T_0 = 10$ (derecha). Fuente: elaboración propia.

3.6 Barrido de K (análisis aparte)

Tabla 5: Reinicios por perturbación según el largo K de la caminata

K	Éxito (%)	Desv.	Evaluac.	Trunc. (%)	Longitud prom.
10	10.3	1.8	9089.0	89.7	21.2
20	32.7	5.5	7568.7	67.3	31.5
50	80.3	5.3	4500.6	19.7	61.5
100	95.0	3.1	2898.4	5.0	110.9
200	97.3	2.5	2545.8	2.7	210.9




Figura 15: Tasa de éxito de reinicios según K ; la línea punteada marca el diámetro del espacio de estados. Fuente: elaboración propia.




Figura 16: Longitud promedio de la solución de reinicios según K (escala logarítmica), frente a la solución óptima máxima (31) y a temple mejor. Fuente: elaboración propia.

3.7 Temple sin tope de evaluaciones

Tabla 6: Temple de la actividad con y sin presupuesto (mismas semillas)

Configuración	Éxito (%)	Desv.	Evaluac.	Trunc. (%)
Con presupuesto (9823)	68.0	7.02	7563.6	32.0
Sin tope	70.3	6.74	9822.6	0.0




Figura 17: Porcentaje de corridas resueltas según las evaluaciones gastadas, para temple de la actividad sin tope. Fuente: elaboración propia.

4 Análisis

4.1 El 8-puzzle exige tolerar empeoramientos

Steepest y estocástico no resolvieron ningún tablero (Tabla 2). Steepest hace en promedio 1.4 movimientos y queda atrapado, con un h final promedio de 12.53 frente a 13.97 inicial. Como cada movimiento cambia h en ± 1 , un ascenso desde un mínimo local no tiene ninguna salida: todos los vecinos empeoran. Para llegar a la meta hay que pasar por estados peores. Esto confirma lo que plantea la teoría: sin un mecanismo para aceptar empeoramientos temporales, la búsqueda local queda atrapada en los mínimos locales del paisaje.

La Figura 10 muestra el mismo fenómeno desde el temple: con $\alpha = 0.01$ la temperatura cae casi de inmediato, el temple deja de aceptar empeoramientos y, como steepest, no resuelve ningún tablero. El barrido de α (Figura 14) lo confirma de forma gradual: con $T_0 = 10$, la tasa de éxito baja a 10.3% con $\alpha = 0.7$ y a 4.0% con $\alpha = 0.5$.

4.2 Los dos mecanismos para aceptar empeoramientos

Los dos algoritmos que resuelven tableros aceptan empeoramientos de formas distintas:

- **Temple:** acepta empeoramientos uno a uno, con probabilidad $e^{-1/T}$, durante toda la búsqueda y de forma cada vez más selectiva.
- **Reinicios por perturbación:** acepta un bloque de K movimientos aleatorios de golpe (la caminata, que empeora o mejora h a ciegas) y después solo acepta mejoras (el ascenso).

Con el mismo presupuesto de 9823 evaluaciones y $K = 20$, temple mejor resuelve el 96.3 % de los tableros gastando en promedio 3074.5 evaluaciones, mientras que reinicios resuelve el 32.7 % gastando 7568.7. Temple supera a reinicios en tasa de éxito y en costo. La diferencia entre las dos tasas (63.7 puntos) es mucho mayor que su variabilidad entre semillas (desviaciones de 4.07 y 5.54).

4.3 La calibración decide el resultado

Ninguno de los dos algoritmos funciona bien con cualquier parámetro. En temple, la tasa de éxito va de 2.0 % a 96.3 % según T_0 y α (Figura 13). Las mejores combinaciones tienen T_0 bajo (1 o 2) y α alto (0.99 a 0.998): una temperatura baja pero sostenida, en la que se acepta entre un tercio y dos tercios de los empeoramientos, funciona mejor que empezar muy caliente. Con T_0 alto (20 o 40) y α alto, el temple pasa casi todo el presupuesto en modo de paseo aleatorio y se trunca antes de enfriarse: con $T_0 = 40$ y $\alpha = 0.998$ se truncan el 97.7 % de las corridas.

La configuración de la actividad ($T_0 = 10$, $\alpha = 0.97$) queda en 68.0 %. Sin tope de evaluaciones sube solo a 70.3 % (Tabla 6): su límite no es el presupuesto, sino el enfriamiento. Aun sin límite de costo, esta configuración gasta 9823 evaluaciones en promedio, más que reinicios con $K = 20$ (7568.7). Como referencia, la configuración del cuaderno exploratorio ($T_0 = 1$, $\alpha = 0.995$, $T_{\min} = 0.01$), corrida sin tope, llegó a 95.3 % con 7132 evaluaciones.

En reinicios, K cumple un papel parecido al de T_0 y α (Tabla 5): con $K = 10$ la caminata casi nunca saca al ascenso de la cuenca del mínimo local (10.3 %), y la tasa de éxito crece con K hasta 97.3 % con $K = 200$. A partir de $K = 100$, reinicios alcanza o supera a temple mejor en tasa de éxito y gasta menos evaluaciones.

4.4 Por qué K grande no es una perturbación local

Con K por encima del diámetro (31), la caminata ya puede llegar a cualquier tablero resoluble, y el reinicio se acerca a lo que hacía la primera implementación: generar table-

ros prácticamente al azar hasta dar con uno desde el que el ascenso llega a la meta. Esa versión llegaba a 99.0 % sin resolver nunca el tablero pedido. Con $K = 200$ el algoritmo ya no aprovecha la estructura del tablero asignado: es fuerza bruta con forma de búsqueda local.

La longitud de la solución lo refleja: crece casi linealmente con K (Figura 16), de 31.5 movimientos con $K = 20$ a 61.5 con $K = 50$, 110.9 con $K = 100$ y 210.9 con $K = 200$, frente a una solución óptima promedio de 22.5. Casi toda la solución es la caminata aleatoria.

Este argumento, sin embargo, no favorece a temple en calidad de solución: las soluciones de temple mejor (1473.7 movimientos en promedio) son unas siete veces más largas que las de reinicios con $K = 200$. La justificación de $K = 20$ se apoya en el diámetro, es decir, en que la perturbación siga siendo local, y no en la longitud de la solución.

4.5 Tasa de éxito frente a calidad de la solución

La comparación entre temple y reinicios con $K = 20$ tiene dos caras:

- **Temple gana en tasa de éxito y en costo:** 96.3 % contra 32.7 % de éxito, con 3074.5 evaluaciones promedio contra 7568.7.
- **Reinicios gana ampliamente en longitud de la solución:** 31.5 movimientos en promedio (1.6 veces la óptima) contra 1473.7 de temple mejor (66.9 veces la óptima) y 5384.9 de temple de la actividad (245 veces la óptima).

La diferencia se explica por el mecanismo de cada algoritmo. El temple no tiene memoria de los estados visitados y, con T cerca de 1, acepta alrededor del 37 % de los movimientos que empeoran h . Por eso zigzaguea: acepta movimientos que deshacen el progreso anterior, vuelve a estados ya visitados y recorre miles de movimientos antes de llegar a la meta (Figura 11). En cambio, el ascenso más pronunciado dentro de reinicios nunca retrocede: cada paso baja h en exactamente 1, así que desde el punto de partida llega a la meta en a lo sumo h pasos. La solución de reinicios es la caminata de K movimientos más un ascenso corto, lo que da caminos cortos por diseño cuando el ascenso encuentra una cuenca favorable.

Hay dos matices. Primero, la longitud de temple incluye todos los ciclos; eliminar los movimientos que se deshacen acortaría sus soluciones, pero eso no se midió en este trabajo. Segundo, reinicios resuelve sobre todo los tableros más fáciles (óptima promedio de 19.9 en sus tableros resueltos, frente a 22.5 en los de temple), lo que también favorece su longitud promedio. Aun con esos matices, la diferencia es de unas 47 veces (casi dos órdenes de magnitud) y no cambia la conclusión.

5 Conclusiones

1. **El ascenso de colinas puro no resuelve el 8-puzzle.** Steepest y estocástico dan 0 % de éxito, y temple con enfriamiento casi inmediato ($\alpha = 0.01$) también. Resolver el 8-puzzle con búsqueda local exige tolerar empeoramientos temporales de $h(s)$, como plantea la teoría.
2. **Temple simulado es superior para encontrar una solución.** Con el mismo presupuesto, temple mejor ($T_0 = 1$, $\alpha = 0.998$) resuelve el 96.3 % de los tableros con 3074.5 evaluaciones promedio, frente a 32.7 % y 7568.7 evaluaciones de reinicios con una perturbación local ($K = 20$).
3. **Pero la solución que entrega temple es mucho menos eficiente en número de movimientos:** 1473.7 movimientos en promedio, 66.9 veces la solución óptima, porque zigzaguea sin memoria de los estados visitados. Reinicios con perturbación acotada al diámetro del problema encuentra soluciones cercanas al óptimo cuando tiene éxito (31.5 movimientos, 1.6 veces la óptima), aunque con menor tasa de éxito y mayor costo en evaluaciones.
4. **La calibración es tan importante como el algoritmo.** Temple va de 2.0 % a 96.3 % según T_0 y α , y reinicios de 10.3 % a 97.3 % según K . Reinicios solo alcanza a temple en tasa de éxito con $K \geq 100$, es decir, cuando la perturbación supera el diámetro del espacio de estados y el reinicio deja de ser una búsqueda local.
5. **Comparar algoritmos estocásticos exige varias corridas.** Una misma configuración de temple varió entre 53.3 % y 90.0 % según la semilla. Sin repetir con varias semillas y sin un presupuesto común de evaluaciones, la comparación depende del azar y de cuánto cómputo recibe cada algoritmo.

En síntesis, la respuesta depende de la pregunta. Si la pregunta es qué algoritmo encuentra una solución con mayor probabilidad y menor costo computacional dentro de una búsqueda local genuina, la respuesta es temple simulado. Si la pregunta es qué algoritmo entrega una mejor solución (una secuencia de movimientos más corta), la respuesta es reinicios con perturbación acotada, en los tableros que logra resolver.

Referencias

Referencias

- [1] Johnson, W. W. y Story, W. E. (1879). Notes on the “15” puzzle. *American Journal of Mathematics*, 2(4), 397–404. <https://doi.org/10.2307/2369492>
- [2] Kirkpatrick, S., Gelatt, C. D. y Vecchi, M. P. (1983). Optimization by simulated annealing. *Science*, 220(4598), 671–680. <https://doi.org/10.1126/science.220.4598.671>
- [3] Metropolis, N., Rosenbluth, A. W., Rosenbluth, M. N., Teller, A. H. y Teller, E. (1953). Equation of state calculations by fast computing machines. *The Journal of Chemical Physics*, 21(6), 1087–1092. <https://doi.org/10.1063/1.1699114>
- [4] Reinefeld, A. (1993). Complete solution of the eight-puzzle and the benefit of node ordering in IDA*. En *Proceedings of the 13th International Joint Conference on Artificial Intelligence (IJCAI)* (pp. 248–253).
- [5] Russell, S. y Norvig, P. (2021). *Artificial Intelligence: A Modern Approach* (4.^a ed.). Pearson.